

# **Unidad 6: Inferencia Estadística: Pruebas de hipótesis paramétricas**

Mg. J. Eduardo Gamboa U.

## **Table of contents**

<b>Descripción del caso</b>	<b>1</b>
<b>Carga de paquetes y lectura de datos</b>	<b>2</b>
<b>Prueba de hipótesis para una media</b>	<b>2</b>
<b>Prueba de hipótesis para una varianza</b>	<b>4</b>
<b>Prueba de hipótesis para una proporción</b>	<b>6</b>
<b>Prueba de hipótesis para dos medias independientes</b>	<b>8</b>
<b>Prueba de hipótesis para dos proporciones</b>	<b>11</b>

## **Descripción del caso**

Mediante el archivo `datos_u6.csv` se busca analizar el consumo mensual de energía junto a diversas características de un edificio y factores ambientales. Contiene datos de varios tipos de edificios, el metraje cuadrado, el número de ocupantes, los electrodomésticos utilizados, la temperatura promedio y el día de la semana.

## Carga de paquetes y lectura de datos

```
library(pacman)
p_load(dplyr, ggplot2, magrittr, EnvStats, binom)

datos <- read.csv('datos_u6.csv')
datos |> rename("TipoEdificio" = 1, "AreaPies2" = 2, "Ocupantes" = 3, "Electro" = 4,
                 "Temperat" = 5, "DiaSemana" = 6, "Consumo" = 7) -> datos
```

## Prueba de hipótesis para una media

¿El consumo promedio mensual de energía eléctrica es superior a los 4000 Kwh?

$$H_0 : \mu \leq 4000 \quad H_1 : \mu > 4000 \quad \alpha = 0.05$$

```
datos |>
  pull(Consumo) |>
  t.test(alternative = "greater", mu = 4000)
```

One Sample t-test

```
data: pull(datos, Consumo)
t = 5.633, df = 999, p-value = 1.151e-08
alternative hypothesis: true mean is greater than 4000
95 percent confidence interval:
 4117.661      Inf
sample estimates:
mean of x
4166.253
```

El pvalor se obtiene de la siguiente manera:

$$pv = P(t_{999} > 5.633) = 1.151 \times 10^{-8}$$

```
pt(q = 5.633, df = 999, lower.tail = F)
```

```
[1] 1.150953e-08
```

```

t_obs <- 5.633
alpha <- 0.05


x_vals <- seq(-4, 6, length.out = 1000)
dens_df <- data.frame(x = x_vals, y = dt(x_vals, 999))
alpha_df <- subset(dens_df, x >= qt(1 - alpha, 999))
pval_df <- subset(dens_df, x >= t_obs)

ggplot(dens_df, aes(x, y)) +
  geom_line(linewidth = 1) +
  geom_area(data = alpha_df, aes(x, y), fill = "red", alpha = 0.5) +
  geom_area(data = pval_df, aes(x, y), fill = "blue", alpha = 0.5) +
  geom_vline(xintercept = t_obs, linetype = "dashed") +
  geom_vline(xintercept = qt(1 - alpha, 999), linetype = "dotted") +
  labs(
    title = "Prueba de hipótesis unilateral derecha",
    subtitle = "Rojo: nivel de significancia ( ), Azul: p-valor",
    x = "t", y = "Densidad")

```

## Prueba de hipótesis unilateral derecha

Rojo: nivel de significancia ( $\alpha$ ), Azul: p-valor



Decisión: Se rechaza  $H_0$

Conclusión: Con un nivel de significancia del 5%, sí existe suficiente evidencia estadística para afirmar que el consumo promedio mensual de energía eléctrica es superior a los 4000 Kwh

## Prueba de hipótesis para una varianza

¿La variabilidad de las temperaturas es menor a 50 °C<sup>2</sup>?

$$H_0 : \sigma^2 \geq 50 \quad H_1 : \sigma^2 < 50 \quad \alpha = 0.05$$

```
library(DescTools)
datos |>
  pull(Temperat) |>
  varTest(sigma.squared = 50, alternative = "less")

$statistic
Chi-Squared
1018.556

$parameters
df
999

$p.value
[1] 0.6734908

$estimate
variance
50.97878

$null.value
variance
50

$alternative
[1] "less"

$method
[1] "Chi-Squared Test on Variance"

$data.name
[1] "pull(datos, Temperat)"

$conf.int
      LCL        UCL
0.00000 54.96016
```

```
attr(,"conf.level")
[1] 0.95
```

```
attr(,"class")
[1] "htestEnvStats"
```

El pvalor se obtiene de la siguiente manera:  $pv = P(\chi^2_{999} < 1018.556) = 0.6735$

```
pchisq(q = 1018.556, df = 999)
```

```
[1] 0.6734907
```


```
chi_obs <- 1018.556; alpha <- 0.05

x_vals <- seq(800, 1200, length.out = 1000)
dens_df <- data.frame(x = x_vals, y = dchisq(x_vals, 999))
alpha_df <- subset(dens_df, x <= qchisq(alpha, 999))
pval_df <- subset(dens_df, x <= chi_obs)

ggplot(dens_df, aes(x, y)) +
  geom_line(linewidth = 1) +
  geom_area(data = alpha_df, aes(x, y), fill = "red", alpha = 0.75) +
  geom_area(data = pval_df, aes(x, y), fill = "blue", alpha = 0.25) +
  geom_vline(xintercept = chi_obs, linetype = "dashed") +
  geom_vline(xintercept = qchisq(alpha, 999), linetype = "dotted") +
  labs(title = "Prueba de hipótesis unilateral izquierda",
       subtitle = "Rojo: nivel de significancia (α), Azul: p-valor",
       x = "Chi2", y = "Densidad")
```

### Prueba de hipótesis unilateral izquierda

Rojo: nivel de significancia ( $\alpha$ ), Azul: p-valor



Decisión: No se rechaza  $H_0$

Conclusión: Con un nivel de significancia del 5%, no existe suficiente evidencia estadística para afirmar que la variabilidad de las temperaturas es menor a  $50^{\circ}C^2$

## Prueba de hipótesis para una proporción

Se dice que si un inmueble posee un área superior a los 15 mil pies cuadrados se le considera “grande”. ¿Se puede señalar que la proporción de inmuebles grandes es del 60%?

$$H_0 : \pi = 0.60 \quad H_1 : \pi \neq 0.60 \quad \alpha = 0.05$$

```
datos |>
  mutate(Tamano = ifelse(AreaPies2>15000, "Grande", "No grande")) |>
  count(Tamano) |> mutate(Prop = n/sum(n)) |> pull(n) -> xn

prop.test(x = xn[1], n = xn[1] + xn[2], p = 0.60, alternative = "two.sided", correct = F)
```

```
1-sample proportions test without continuity correction

data: xn[1] out of xn[1] + xn[2], null probability 0.6
X-squared = 51.337, df = 1, p-value = 7.778e-13
alternative hypothesis: true p is not equal to 0.6
95 percent confidence interval:
 0.6821396 0.7382455
sample estimates:
    p 
0.711
```

El pvalor se obtiene de la siguiente manera:

$$Z_{calc} = \frac{0.711 - 0.6}{\sqrt{\frac{0.6 \times 0.4}{1000}}} = 7.165019$$

$$pv = 2P(Z > 7.165019) = 7.778 \times 10^{-13}$$

```
2*pnorm(q = 7.165019, lower.tail = F)
```

```
[1] 7.777577e-13
```

```

z_obs <- 7.165019
alpha <- 0.05


x_vals <- seq(-8, 8, length.out = 1000)
dens_df <- data.frame(x = x_vals, y = dnorm(x_vals))
alpha_df_left <- subset(dens_df, x <= qnorm(alpha / 2))
alpha_df_right <- subset(dens_df, x >= qnorm(1 - alpha / 2))
pval_df_left <- subset(dens_df, x <= -abs(z_obs))
pval_df_right <- subset(dens_df, x >= abs(z_obs))

ggplot(dens_df, aes(x, y)) +
  geom_line(linewidth = 1) +
  geom_area(data = alpha_df_left, aes(x, y), fill = "red", alpha = 0.5) +
  geom_area(data = alpha_df_right, aes(x, y), fill = "red", alpha = 0.5) +
  geom_area(data = pval_df_left, aes(x, y), fill = "blue", alpha = 0.5) +
  geom_area(data = pval_df_right, aes(x, y), fill = "blue", alpha = 0.5) +
  geom_vline(xintercept = z_obs, linetype = "dashed") +
  geom_vline(xintercept = -z_obs, linetype = "dashed") +
  geom_vline(xintercept = qnorm(1 - alpha/2), linetype = "dotted") +
  geom_vline(xintercept = qnorm(alpha/2), linetype = "dotted") +
  labs(title = "Prueba de hipótesis bilateral",
       subtitle = "Rojo: nivel de significancia (), Azul: p-valor",
       x = "t", y = "Densidad")

```

## Prueba de hipótesis bilateral

Rojo: nivel de significancia ( $\alpha$ ), Azul: p-valor



Decisión: Se rechaza  $H_0$

Conclusión: Con un nivel de significancia del 5%, no existe suficiente evidencia estadística para afirmar que la proporción de inmuebles grandes es del 60%.

## Prueba de hipótesis para dos medias independientes

¿El consumo medio de energía en los edificios industriales supera en más de 500 Kwh a los comerciales? Considerar  $\alpha = 0.01$ .

Primero, se prueba la igualdad de varianzas:

$$H_0 : \frac{\sigma_1^2}{\sigma_2^2} = 1 \quad H_1 : \frac{\sigma_1^2}{\sigma_2^2} \neq 1 \quad \alpha = 0.01$$

```
datos > filter(TipoEdificio %in% c("Commercial", "Industrial")) -> datos_2medias
var.test(formula      = Consumo ~ TipoEdificio,
         data        = datos_2medias,
         alternative = "two.sided")
```

```
F test to compare two variances

data: Consumo by TipoEdificio
F = 0.95337, num df = 335, denom df = 316, p-value = 0.6662
alternative hypothesis: true ratio of variances is not equal to 1
95 percent confidence interval:
 0.7665537 1.1848793
sample estimates:
ratio of variances
 0.953368

# Notar que en vez de declarar las dos muestras, estamos indicando
# variable y ~ variable de grupos
```

¿Cómo se calculó el p-valor?

$$pv = 2P(F_{335,316} < 0.953368) = P(F_{335,316} < 0.953368) + P(F_{335,316} > 1/0.953368) = 0.667$$

```
2*pf(0.953368, 335, 316)
```

```
[1] 0.6661578
```

```
pf(0.953368, 335, 316) + (1-pf(1/0.953368, 335, 316))
```

```
[1] 0.6670156
```

```

f_obs <- 0.953368
alpha <- 0.01


x_vals <- seq(0,1.5, length.out = 1000)
dens_df <- data.frame(x = x_vals, y = df(x_vals,335,316))
alpha_df_left <- subset(dens_df, x <= qf(alpha / 2, 335, 316))
alpha_df_right <- subset(dens_df, x >= qf(1 - alpha / 2, 335, 316))
pval_df_right <- subset(dens_df, x <= f_obs)
pval_df_left <- subset(dens_df, x >= 1/f_obs)

ggplot(dens_df, aes(x, y)) +
  geom_line(linewidth = 1) +
  geom_area(data = alpha_df_left, aes(x, y), fill = "red", alpha = 0.5) +
  geom_area(data = alpha_df_right, aes(x, y), fill = "red", alpha = 0.5) +
  geom_area(data = pval_df_right, aes(x, y), fill = "blue", alpha = 0.5) +
  geom_area(data = pval_df_left, aes(x, y), fill = "blue", alpha = 0.5) +
  geom_vline(xintercept = f_obs, linetype = "dashed") +
  geom_vline(xintercept = qf(1 - alpha/2, 335, 316), linetype = "dotted") +
  geom_vline(xintercept = qf(alpha/2, 335, 316), linetype = "dotted") +
  labs(title = "Prueba de hipótesis bilateral",
       subtitle = "Rojo: nivel de significancia (), Azul: p-valor",
       x = "F", y = "Densidad")

```

## Prueba de hipótesis bilateral

Rojo: nivel de significancia ( $\alpha$ ), Azul: p-valor



Dado que  $p> > \alpha$ , entonces no se rechaza  $H_0$ . En conclusión, las varianzas son homogéneas. Sabiendo esto, se pasa a comparar las medias.

El enunciado señala que se debe verificar la afirmación  $\mu_I - \mu_C > 500$ , sin embargo R toma por defecto los niveles en orden alfabético, es decir primero “Commercial” y luego “Industrial”.

Hay 2 opciones: Reordenar los niveles, o reordenar la hipótesis. Eligiendo esta última opción tendríamos que la afirmación inicial es equivalente a  $\mu_C - \mu_I < -500$ .

Por lo tanto:

$$H_0 : \mu_C - \mu_I \geq -500 \quad H_1 : \mu_C - \mu_I < -500 \quad \alpha = 0.01$$

```
t.test(formula = Consumo ~ TipoEdificio, data = datos_2medias, mu = -500,
       alternative = "less", var.equal = T)
```

Two Sample t-test

```
data: Consumo by TipoEdificio
t = -1.6384, df = 651, p-value = 0.05091
alternative hypothesis: true difference in means between group Commercial and group Industrial
95 percent confidence interval:
-Inf -499.4383
sample estimates:
mean in group Commercial mean in group Industrial
        4130.024                  4735.143
```

¿Cómo se calculó el p-valor?

$$pv = P(t_{651} < -1.6384) = 0.0509$$

```
pt(q = -1.6384, df = 651)
```

[1] 0.05091073

```
t_obs <- -1.6384
alpha <- 0.01

x_vals <- seq(-3,3, length.out = 1000)
dens_df <- data.frame(x = x_vals, y = dt(x_vals, 651))
alpha_df <- subset(dens_df, x <= qt(alpha, 651))
pval_df <- subset(dens_df, x <= t_obs)

ggplot(dens_df, aes(x, y)) +
  geom_line(linewidth = 1) +
  geom_area(data = alpha_df, aes(x, y), fill = "red", alpha = 0.75) +
```


```

geom_area(data = pval_df, aes(x, y), fill = "blue", alpha = 0.5) +
geom_vline(xintercept = t_obs, linetype = "dashed") +
geom_vline(xintercept = qt(alpha, 651), linetype = "dotted") +
labs(title = "Prueba de hipótesis unilateral a la izquierda",
     subtitle = "Rojo: nivel de significancia (), Azul: p-valor",
     x = "t", y = "Densidad")

```

## Prueba de hipótesis unilateral a la izquierda

Rojo: nivel de significancia ( $\alpha$ ), Azul: p-valor



Decisión: Dado que  $p v > \alpha$ , no se rechaza la hipótesis nula.

Conclusión: el consumo medio de energía en los edificios industriales no supera en más de 500 Kwh a los comerciales.

## Prueba de hipótesis para dos proporciones

Se dice que si un inmueble posee un área superior a los 15 mil pies cuadrados se le considera “grande”. ¿Se puede señalar que la proporción de inmuebles comerciales grandes es mayor que los industriales?

$$H_0 : \pi_1 - \pi_2 \leq 0 \quad H_1 : \pi_1 - \pi_2 > 0 \quad \alpha = 0.05$$

```

datos |>
  filter(TipoEdificio %in% c("Commercial", "Industrial")) |>
  mutate(Tamano = ifelse(AreaPies2>15000, "Grande", "No grande")) |>
  group_by(TipoEdificio) |>
  count(Tamano) |> mutate(Prop = n/sum(n)) -> tabla

```

tabla

```

# A tibble: 4 x 4
# Groups:   TipoEdificio [2]
  TipoEdificio Tamano      n  Prop
  <chr>        <chr>    <int> <dbl>
1 Commercial   Grande     233 0.693
2 Commercial   No grande 103 0.307
3 Industrial   Grande    231 0.729
4 Industrial   No grande 86 0.271

```

```

prop.test(x = tabla$n[c(1,3)],
          n = tabla$n[c(1,3)]+tabla$n[c(2,4)],
          alternative = "greater", correct = F)

```

```

2-sample test for equality of proportions without continuity correction

data:  tabla$n[c(1, 3)] out of tabla$n[c(1, 3)] + tabla$n[c(2, 4)]
X-squared = 0.98572, df = 1, p-value = 0.8396
alternative hypothesis: greater
95 percent confidence interval:
-0.09355509  1.00000000
sample estimates:
prop 1   prop 2
0.6934524 0.7287066

```

El pvalor se halla de la siguiente manera:

$$P(Z > -0.9928357) = P(\chi_1^2 > 0.98572) = 0.8396$$

```

p1 = 233/336 # 0.69345
p2 = 231/317 # 0.72871
p  = 464/653 # 0.71057
(zc = (p1-p2)/sqrt(p*(1-p)*(1/336+1/317)))

```

```
[1] -0.9928357
```

```
pnorm(q = zc, lower.tail = F)
```

```
[1] 0.839605
```


```
z_obs <- -0.9928357
alpha <- 0.05

x_vals <- seq(-3,3, length.out = 1000)
dens_df <- data.frame(x = x_vals, y = dnorm(x_vals))
alpha_df <- subset(dens_df, x >= qnorm(1-alpha))
pval_df <- subset(dens_df, x >= z_obs)

ggplot(dens_df, aes(x, y)) +
  geom_line(linewidth = 1) +
  geom_area(data = alpha_df, aes(x, y), fill = "red", alpha = 0.75) +
  geom_area(data = pval_df, aes(x, y), fill = "blue", alpha = 0.5) +
  geom_vline(xintercept = z_obs, linetype = "dashed") +
  geom_vline(xintercept = qnorm(1-alpha), linetype = "dotted") +
  labs(title = "Prueba de hipótesis unilateral a la derecha",
       subtitle = "Rojo: nivel de significancia (), Azul: p-valor",
       x = "N(0,1)", y = "Densidad")
```

### Prueba de hipótesis unilateral a la derecha

Rojo: nivel de significancia ( $\alpha$ ), Azul: p-valor



Decisión: Dado que  $pv > \alpha$ , no se rechaza la hipótesis nula.

Conclusión: No existe evidencia estadística para señalar que la proporción de inmuebles comerciales grandes es mayor que los industriales