



Métodos Estadísticos y Simulación

Unidad 7: Inferencia Estadística: Pruebas de hipótesis no paramétricas

Mg. J. Eduardo Gamboa U.

2026-07-11

Introducción

¿Por qué importa la distribución de los datos?

En las pruebas de hipótesis paramétricas hemos asumido supuestos acerca de la distribución de los datos y/o el tamaño de muestra. Sin embargo, no habíamos realizado la verificación de dichos supuestos.

Cuando no se cumplen estos supuestos, se debe optar por el uso de pruebas no paramétricas, que se caracterizan por su robustez ante el incumplimiento de supuestos. No obstante, usadas incorrectamente, las pruebas no paramétricas pueden perder potencia y descartar información al usar rangos en vez de los datos originales.

Pruebas de bondad de ajuste

Una prueba de bondad de ajuste compara las frecuencias observadas o la distribución empírica de los datos con las frecuencias esperadas bajo la hipótesis nula de que los datos provienen de una distribución específica H_0 .

Para verificación de ajuste a distribuciones discretas tenemos la prueba Chi cuadrado, mientras que para continuas, la de Kolmogorov Smirnov (y otras más que son específicas para normalidad).

Prueba Chi Cuadrado

Busca probar si al menos una de las probabilidades teóricas (π_i) de las categorías de una variable nominal es diferente a al menos una de las especificadas.

Para ello, compara las frecuencias observadas o_i con las esperadas o teóricas e_i , bajo la restricción de que $\sum_{i=1}^k \pi_i = 1$, siendo k el número de categorías o valores que toma la variable discreta en análisis.

Ejemplo

En una planta embotelladora se cuenta con tres líneas de producción. El supervisor desea determinar si las tres líneas producen la misma proporción de botellas, considerando un 5% de significancia. Se seleccionan al azar 180 botellas producidas durante una jornada y se clasifican según la línea de procedencia, obteniendo 52 botellas de la línea A, 71 de la B y 57 de la C.

$$H_0 : \pi_A = \pi_B = \pi_C = \frac{1}{3}$$

H_1 : Al menos un π es distinto

$$\alpha = 0.05$$

```
o_i  <- c("Línea A" = 52, "Línea B" = 71, "Línea C" = 57)
pi_i <- c(1/3, 1/3, 1/3)

chisq.test(x = o_i, p = pi_i)
```

Chi-squared test for given probabilities

data: o_i

X-squared = 3.2333, df = 2, p-value = 0.1986

Con un n.s. del 5%, no se rechaza H_0 , por lo tanto la proporción de botellas producidas por las tres líneas es la misma.

Ejemplo

En una clínica de atención primaria, el administrador desea verificar si el número de pacientes que llegan al servicio de emergencias por hora puede modelarse mediante una distribución de Poisson. Para ello, registra el número de pacientes que llegaron durante 20 horas seleccionadas aleatoriamente, obteniéndose los siguientes datos:

0,1,2,1,0,1,3,1,0,2,1,0,2,1,0,3,2,0,1,2

Utilice un nivel de significancia del 10% para determinar si el número de pacientes por hora puede modelarse mediante una distribución de Poisson.

H_0 : El número de pacientes por hora se ajusta a una distribución Poisson

H_1 : El número de pacientes por hora no se ajusta a una distribución Poisson

$\alpha = 0.10$

```
pacientes <- c(0,1,2,1,0,1,3,1,0,2,1,0,2,1,0,3,2,0,1,2)
lambda_est <- mean(pacientes)
lambda_est
```

```
[1] 1.15
```

H_0 : El número de pacientes por hora se ajusta a una distribución Poisson con $\lambda = 1.15$

H_1 : El número de pacientes por hora no se ajusta a una distribución Poisson con $\lambda = 1.15$


```
o1 = sum(pacientes == 0); o1
```

```
[1] 6
```

```
p1 = dpois(x = 0, lambda = lambda_est); p1
```

```
[1] 0.3166368
```

```
o2 = sum(pacientes == 1); o2
```

```
[1] 7
```

```
p2 = dpois(x = 1, lambda = lambda_est); p2
```

```
[1] 0.3641323
```

```
o3 = sum(pacientes >= 2); o3
```

```
[1] 7
```

```
p3 = 1 - ppois(q = 1, lambda = lambda_est); p3
```

```
[1] 0.3192309
```

```
p1 + p2 + p3
```

```
[1] 1
```

```
chisq.test(x = c(o1, o2, o3), p = c(p1, p2, p3))
```

Chi-squared test for given probabilities

```
data: c(o1, o2, o3)
```

```
X-squared = 0.087766, df = 2, p-value = 0.9571
```

Se debe tener cuidado porque la salida de R no sabe que el parámetro ha sido estimado, por lo que se debe restar un grado de libertad.

Así $\chi^2_{calc} = 0.087766$ pero $gl = 3 - 1 - 1 = 1$, por lo tanto:

$$pv = P(\chi^2_1 > 0.087766) = 0.7672$$

```
1 - pchisq(q = 0.08766, df = 1)
```

```
[1] 0.7671733
```

No se rechaza H_0 , por lo tanto existe evidencia de que el número de pacientes por hora se ajusta a una distribución Poisson con $\lambda = 1.15$

Ejemplo

Una empresa de ventas telefónicas desea estudiar cuántas llamadas necesita realizar un vendedor hasta concretar su primera venta. Se sospecha que el número de intentos sigue una distribución geométrica, y se busca verificar esta afirmación con $\alpha = 0.05$

Se seleccionan aleatoriamente 21 vendedores y se registra el número de llamadas realizadas antes de conseguir la primera venta. Los resultados fueron los siguientes:

2,0,1,0,2,0,1,0,3,1,0,2,0,1,0,4,1,0,2,0,1

H_0 : El número de llamadas antes de concretar la primera venta se ajusta a una distribución geométrica

H_1 : El número de llamadas antes de concretar la primera venta no se ajusta a una distribución geométrica

$$\alpha = 0.10$$

```
llamadas <- c(2,0,1,0,2,0,1,0,3,1,0,2,0,1,0,4,1,0,2,0,1)
p_est    <- 1/(1+mean(llamadas))
p_est
```

[1] 0.5

H_0 : El número de llamadas antes de concretar la primera venta se ajusta a una distribución geométrica $\pi = 0.5$

H_1 : El número de llamadas antes de concretar la primera venta no se ajusta a una distribución geométrica $\pi = 0.5$

```
o1 = sum(llamadas == 0); o1
```

```
[1] 9
```

```
p1 = dgeom(x = 0, prob = p_est); p1
```

```
[1] 0.5
```

```
o2 = sum(llamadas == 1); o2
```

```
[1] 6
```

```
p2 = dgeom(x = 1, prob = p_est); p2
```

```
[1] 0.25
```

```
o3 = sum(llamadas >= 2); o3
```

```
[1] 6
```

```
p3 = 1 - pgeom(q = 1, prob = p_est); p3
```

```
[1] 0.25
```

```
p1 + p2 + p3
```

```
[1] 1
```

```
chisq.test(x = c(o1, o2, o3), p = c(p1, p2, p3))
```

Chi-squared test for given probabilities

```
data:  c(o1, o2, o3)
```

```
X-squared = 0.42857, df = 2, p-value = 0.8071
```

Se debe tener cuidado porque la salida de R no sabe que el parámetro ha sido estimado, por lo que se debe restar un grado de libertad.

Así $\chi_{calc}^2 = 0.42857$ pero $gl = 3 - 1 - 1 = 1$, por lo tanto:

$$pv = P(\chi_1^2 > 0.42857) = 0.5127$$

```
1 - pchisq(q = 0.42857, df = 1)
```

```
[1] 0.5126915
```

No se rechaza H_0 , por lo tanto existe evidencia de que el número de llamadas antes de concretar la venta sí se ajusta a una distribución Geométrica con $\pi = 0.5$.

Ejemplo

¿El número de mascotas de los estudiantes se ajusta a una distribución Poisson con media 2? Considerar $\alpha = 0.10$

Se ha registrado los siguientes valores: 2, 3, 2, 0, 2, 0, 3, 1, 2, 4, 0

```
mascotas <- c(2, 3, 2, 0, 2, 0, 3, 1, 2, 4, 0, 0)
o1 <- sum(mascotas <= 1); o1
```

```
[1] 5
```

```
p1 <- ppois(1, lambda = 2); p1
```

```
[1] 0.4060058
```

```
e1 <- 12*p1; e1
```

```
[1] 4.87207
```

```
o2 <- sum(mascotas >= 2); o2
```

```
[1] 7
```

```
p2 <- 1-ppois(1, lambda = 2); p2
```

```
[1] 0.5939942
```

```
e2 <- 12*p2; e2
```

```
[1] 7.12793
```


H_0 : El número de personas con mascotas sigue una distribución Poisson con $\lambda = 2$

H_1 : El número de personas con mascotas NO sigue una distribución Poisson con $\lambda = 2$

$\alpha = 0.10$

```
chisq.test(x = c(o1, o2), p = c(p1, p2))
```

Chi-squared test for given probabilities

```
data:  c(o1, o2)
```

```
X-squared = 0.0056552, df = 1, p-value = 0.9401
```

$p\text{-value} = 0.9401$, no se rechaza H_0 . Por lo tanto, existe evidencia de que el número de personas con mascotas sigue una distribución Poisson con $\lambda = 2$.

Prueba de Kolmogorov-Smirnov

- ▶ La prueba de K-S fue propuesta por Andréi Kolmogórov (1903 - 1987) y Nikolái Smirnov (1900 - 1966)
- ▶ Compara la distribución de distribución acumulada empírica $F_n(x)$ con la teórica $F(x)$ mediante el estadístico de prueba:

$$D = \max |F_n(x) - F(x)|$$

- ▶ Se debe conocer los parámetros de la distribución en cuestión.
- ▶ Se sugiere su uso para datos continuos.

Ejemplo

¿Los siguientes datos se ajustan a una distribución uniforme en el intervalo $[0, 1]$?

Considerar $\alpha = 0.10$

0.9876, 0.7883, 0.4090, 0.8830, 0.9405, 0.0456, 0.5281, 0.8924, 0.5514, 0.9566

H_0 : Los datos se ajustan a la distribución $U(0, 1)$

H_1 : Los datos no se ajustan a la distribución $U(0, 1)$

$\alpha = 0.10$

```
datos <- c(0.9876,0.7883,0.4090,0.8830,0.9405,0.0456,0.5281,0.8924,  
          0.5514,0.9566)  
datos |> ks.test("punif", min = 0, max = 1)
```

Exact one-sample Kolmogorov-Smirnov test

data: datos

D = 0.3883, p-value = 0.07225

alternative hypothesis: two-sided

Con un n.s. del 10%, se rechaza H_0 , por lo tanto los datos no se ajustan a una distribución uniforme en el intervalo $[0,1]$.

Ejemplo

Una municipalidad quiere saber si el tiempo de atención (en minutos) de sus ventanillas sigue una distribución exponencial con tiempo medio de 5 minutos, porque esperan que los tiempos entre atenciones sean aleatorios y con una tasa constante.

Los tiempos registrados son los siguientes:

4.22, 2.88, 6.65, 0.16, 0.28, 1.58, 12.57, 0.73, 13.63

H_0 : Los datos se ajustan a la distribución $Exp(\lambda = 0.2)$

H_1 : Los datos no se ajustan a la distribución $Exp(\lambda = 0.2)$

$\alpha = 0.10$

```
datos <- c(4.22, 2.88, 6.65, 0.16, 0.28, 1.58, 12.57, 0.73, 13.63)
datos |> ks.test("pexp", rate = 1/5)
```

Exact one-sample Kolmogorov-Smirnov test

data: datos

D = 0.19749, p-value = 0.8102

alternative hypothesis: two-sided

Con un n.s. del 10%, no se rechaza H_0 , por lo tanto los datos sí se ajustan a una distribución exponencial con media de 5 minutos.

Ejemplo

Un psicólogo registró los tiempos de reacción (en segundos) de estudiantes ante un estímulo visual. Queremos verificar si estos tiempos siguen una distribución normal con media $\mu = 1.5$ y desviación estándar $\sigma = 0.5$. Los tiempos registrados son los siguientes:

1.2, 1.4, 2.3, 1.5, 1.6, 2.4, 1.7, 0.9

H_0 : Los datos se ajustan a la distribución $N(\mu = 1.5, \sigma^2 = 0.5^2)$

H_1 : Los datos no se ajustan a la distribución $N(\mu = 1.5, \sigma^2 = 0.5^2)$

$\alpha = 0.10$

```
tiempos <- c(1.2,1.4,2.3,1.5,1.6,2.4,1.7,0.9)
tiempos |> ks.test("pnorm", mean = 1.5, sd = 0.5)
```

Exact one-sample Kolmogorov-Smirnov test

data: tiempos

D = 0.1952, p-value = 0.8674

alternative hypothesis: two-sided

Con un n.s. del 10%, no se rechaza H_0 , por lo tanto los datos sí se ajustan a una distribución normal con media de 1.5 segundos y desviación estándar de 0.5 segundo.

Prueba de Lilliefors

- ▶ Propuesta por Hubert Lilliefors (1928 - 2008).
- ▶ Se utiliza cuando se desea probar normalidad en un conjunto de datos sin asumir valores específicos para los parámetros, por lo que deben ser estimados.

Ejemplo

Un psicólogo registró los tiempos de reacción (en segundos) de estudiantes ante un estímulo visual. Queremos verificar si estos tiempos siguen una distribución normal.

Los tiempos registrados son los siguientes:

1.2, 1.4, 2.3, 1.5, 1.6, 2.4, 1.7, 0.9

H_0 : Los datos se ajustan a la distribución normal

H_1 : Los datos no se ajustan a la distribución normal

$\alpha = 0.10$

```
tiempos <- c(1.2,1.4,2.3,1.5,1.6,2.4,1.7,1.9)
library(nortest)
tiempos |> lillie.test()
```

Lilliefors (Kolmogorov-Smirnov) normality test

data: tiempos

D = 0.17191, p-value = 0.6941

```
tiempos |> mean()
```

```
[1] 1.75
```

```
tiempos |> sd()
```

```
[1] 0.4242641
```

Con un n.s. del 10%, no se rechaza H_0 , por lo tanto los datos sí se ajustan a una distribución normal con media $\mu = 1.75$ y desviación estándar $\sigma = 0.424$.

Prueba de Shapiro Wilk

- ▶ Está diseñada específicamente para probar normalidad.
- ▶ Es más potente, incluso para muestras pequeñas.
- ▶ Si la muestra es grande (mayor a 2000), y se rechaza la hipótesis nula de normalidad, complementar con gráficos (histograma, boxplot, qqplot).
- ▶ Es sensible a outliers.
- ▶ No se invalida la prueba si se estima μ y σ^2 a partir de la muestra.

Ejemplo (cont.)

```
tiempos <- c(1.2,1.4,2.3,1.5,1.6,2.4,1.7,1.9)
tiempos |> shapiro.test()
```

Shapiro-Wilk normality test


data: tiempos

W = 0.93678, p-value = 0.5797

Con un n.s. del 10%, se rechaza H_0 , por lo tanto los datos no se ajustan a una distribución normal con media $\mu = 1.75$ y desviación estándar $\sigma = 0.424$.


```
library(ggplot2)
tiempos |>
  data.frame() |>
  ggplot(aes(x = tiempos)) +
  geom_histogram(binwidth = 0.2, fill = "skyblue", color = "black") +
  labs(title = "Histograma de tiempos", x = "Tiempos", y = "Frecuencia") +
  theme_minimal()
```

Histograma de tiempos




```
tiempos |>  
  data.frame() |>  
  ggplot(aes(y = tiempos)) +  
  geom_boxplot(fill = "lightgreen", color = "black") +  
  labs(title = "Boxplot de tiempos", y = "Tiempos") +  
  theme_minimal()
```


Boxplot de tiempos



```
tiempos |>  
  data.frame() |>  
  ggplot(aes(sample = tiempos)) +  
  stat_qq() +  
  stat_qq_line(color = "red") +  
  labs(title = "Q-Q Plot de tiempos") +  
  theme_minimal()
```

Q-Q Plot de tiempos



Otras pruebas de normalidad

- ▶ Anderson Darling: enfocada principalmente en evaluar las colas de la distribución, sensible a valores extremos
- ▶ Jarque-Bera: utiliza el tercer y cuarto momento para decidir acerca de la normalidad.

Pruebas no paramétricas en una población

Usarlas cuando los datos no son normales (verificado con Shapiro-Wilk o Lilliefors) y la muestra es pequeña (menor a 30); o cuando la variable está medida en escala ordinal.

Se tienen las siguientes pruebas:

- ▶ Prueba del signo
- ▶ Prueba de Wilcoxon

Prueba del signo

- ▶ Verifica si la mediana de la población es igual a un valor hipotético Me_0 contrastando las hipótesis:

$$H_0 : Me = Me_0 \quad H_1 : Me \neq Me_0$$

- ▶ Usa solo los signos (+ o -) de las diferencias entre los datos y la mediana hipotética Me_0 .
- ▶ Puede evaluarse también de manera unilateral, a la derecha o a la izquierda.

Prueba de Wilcoxon (o de rango con signo)

- ▶ Verifica si la mediana de la población es igual a un valor hipotético Me_0 , contrastando las hipótesis:

$$H_0 : Me = Me_0 \quad H_1 : Me \neq Me_0$$

- ▶ Considera tanto el signo como el tamaño de las diferencias (rango con signo).
- ▶ Es más potente que la prueba de signos, pero requiere que las diferencias sean simétricas alrededor de la mediana.
- ▶ Puede evaluarse también de manera unilateral, a la derecha o a la izquierda.

Ejemplo

Un investigador quiere saber si la mediana del tiempo que las personas pasan en una página web es 10 minutos, y para ello toma una muestra aleatoria de 7 usuarios, registrando los siguientes tiempos:

12, 8, 15, 13, 7, 43, 5

Verificamos normalidad:

H_0 : El tiempo de permanencia en la página web sigue una distribución Normal

H_1 : El tiempo de permanencia en la página web no sigue una distribución Normal

$\alpha = 0.10$

```
tiempos = c(12,8,15,13,7,43,5)
tiempos |> lillie.test()
```

Lilliefors (Kolmogorov-Smirnov) normality test

data: tiempos

D = 0.34836, p-value = 0.01033

```
tiempos |> shapiro.test()
```

Shapiro-Wilk normality test

data: tiempos

W = 0.71195, p-value = 0.004998

No se cumple el supuesto de normalidad, y el tamaño de muestra es pequeño.

$$H_0 : Me = 10 \quad H_1 : Me \neq 10 \quad \alpha = 0.10$$

```
(tiempos - 10) |> mean()
```

```
[1] 4.714286
```

```
(tiempos - 10) |> median()
```

```
[1] 2
```

Se aprecia que las diferencias no son simétricas, por lo que es más conveniente usar la prueba del signo.

```
library(BSDA)
tiempos |> SIGN.test(md = 10, alternative = "two.sided")
```

One-sample Sign-Test

```
data:  tiempos
s = 4, p-value = 1
alternative hypothesis: true median is not equal to 10
95 percent confidence interval:
 5.628571 34.200000
sample estimates:
median of x
      12
```

Achieved and Interpolated Confidence Intervals:

	Conf.Level	L.E.pt	U.E.pt
Lower Achieved CI	0.8750	7.0000	15.0
Interpolated CI	0.9500	5.6286	34.2
Upper Achieved CI	0.9844	5.0000	43.0

Se puede afirmar que el tiempo mediano de permanencia en la página web es de 10 minutos.

Ejemplo

Un investigador mide los tiempos (en segundos) que toma a 9 estudiantes resolver un problema matemático. Quiere saber si la mediana poblacional del tiempo es mayor a 18 segundos. Los tiempos registrados son:

4, 20, 21, 29, 10, 20, 2, 66, 9

Verificamos normalidad:

H_0 : El tiempo de resolución del problema matemático sigue una distribución Normal

H_1 : El tiempo de resolución del problema matemático no sigue una distribución Normal

$\alpha = 0.10$

```
tiempos = c(4,20,21,29,10,20,2,66,9)
tiempos |> lillie.test()
```

Lilliefors (Kolmogorov-Smirnov) normality test

data: tiempos

D = 0.25947, p-value = 0.08174

```
tiempos |> shapiro.test()
```

Shapiro-Wilk normality test

data: tiempos

W = 0.80425, p-value = 0.02283

No se cumple el supuesto de normalidad, y el tamaño de muestra es pequeño.

$$H_0 : Me \leq 18 \quad H_1 : Me > 18 \quad \alpha = 0.10$$

```
(tiempos - 18) |> mean()
```

```
[1] 2.111111
```

```
(tiempos - 18) |> median()
```

```
[1] 2
```

Se aprecia simetría de las diferencias, por lo que es conveniente utilizar la prueba de Wilcoxon.


```
tiempos |> wilcox.test(mu = 18, alternative = "greater")
```

Wilcoxon signed rank test with continuity correction

data: tiempos

V = 21, p-value = 0.5937

alternative hypothesis: true location is greater than 18

No se rechaza H_0 , por lo tanto no hay evidencia estadística para afirmar que la mediana poblacional del tiempo es mayor a 18 segundos.

Pruebas no paramétricas en dos poblaciones

- ▶ Si las muestras provienen de poblaciones independientes, la variable es cuantitativa y no se verifica normalidad: Prueba U de Mann Whitney.
- ▶ Si las muestras provienen de poblaciones relacionadas, la variable es cuantitativa y no se verifica normalidad en la diferencia: Prueba de Wilcoxon para datos pareados.

Ejemplo

Una ONG evalúa el impacto de dos campañas ambientales sobre la actitud hacia el reciclaje en dos comunidades distintas:

- ▶ Comunidad A: Vio la campaña en redes sociales.
- ▶ Comunidad B: Participó en talleres presenciales.

Se preguntó: “En una escala del 1 al 20, ¿cuánto te comprometes a separar residuos?, donde 1 significa Nada comprometido y 20 Muy comprometido.

Se recolectaron los siguientes datos:

- ▶ Comunidad A: 1,8,3,4
- ▶ Comunidad B: 11,15,7,18,6

¿Existe diferencia significativa en el nivel de compromiso entre ambas comunidades?

H_0 : No hay diferencia entre las distribuciones de compromiso ($Me_A = Me_B$)

H_1 : Las distribuciones de compromiso difieren ($Me_A \neq Me_B$)

$\alpha = 0.10$

```
A <- c(1,8,3,4)
B <- c(11,15,7,18, 6)
A |> wilcox.test(B, alternative = "two.sided", paired = FALSE)
```

Wilcoxon rank sum exact test

data: A and B

$W = 2$, p-value = 0.06349

alternative hypothesis: true location shift is not equal to 0

Con un nivel de significancia del 10%, existe evidencia estadística para afirmar que las distribuciones de compromiso difieren entre las comunidades A y B.

Ejemplo

Un médico quiere evaluar si un nuevo medicamento reduce la presión arterial sistólica.

Mide la presión en 10 pacientes antes y después del tratamiento:

- ▶ Antes: 145, 150, 138, 142, 148, 135, 140, 155, 149, 151
- ▶ Después: 140, 144, 137, 140, 142, 130, 136, 150, 143, 147

H_0 : La mediana de las diferencias antes-después es menor o igual a 0

H_1 : La mediana de las diferencias antes-después es mayor a 0

$\alpha = 0.10$

```
antes = c(145,150,138,142,148,135,140, 155,149,151)
despues = c(140,144,137,140,142,130,136,150,143,147)
antes |> wilcox.test(despues, alternative = "greater", paired = TRUE)
```

Wilcoxon signed rank test with continuity correction

data: antes and despues

$V = 55$, $p\text{-value} = 0.002817$

alternative hypothesis: true location shift is greater than 0

```
andes = antes - despues  
andes |> wilcox.test(alternative = "greater")
```

Wilcoxon signed rank test with continuity correction

```
data: andes  
V = 55, p-value = 0.002817  
alternative hypothesis: true location is greater than 0
```

```
andes |> mean()
```

```
[1] 4.4
```

Con un nivel de significancia del 10%, existe evidencia estadística para afirmar que el nuevo medicamento sí reduce la presión arterial sistólica.